

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH  
TRƯỜNG ĐẠI HỌC BÁCH KHOA  
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



KHO DỮ LIỆU  
VÀ HỆ HỖ TRỢ QUYẾT ĐỊNH – CO4031

---

BÀI TẬP LỚN  
THIẾT KẾ VÀ XÂY DỰNG KHO DỮ LIỆU  
CRYPTO HỖ TRỢ PHÂN TÍCH VÀ DỰ  
BÁO THỊ TRƯỜNG

---

Giảng viên hướng dẫn: ThS. Bùi Tiến Đức

Lớp: L02

|                      |                       |         |
|----------------------|-----------------------|---------|
| Sinh viên thực hiện: | Đinh Lê Phúc Duy      | 2210500 |
|                      | Nguyễn Hồ Phước Hiền  | 2211027 |
|                      | Phạm Thanh Phong      | 2212564 |
|                      | Nguyễn Võ Công Phương | 2212700 |
|                      | Nguyễn Bá Việt Quang  | 2212741 |



## Phân công nhiệm vụ

| STT | Họ tên                | MSSV    | Mô tả đóng góp                                   | Tỉ lệ đóng góp |
|-----|-----------------------|---------|--------------------------------------------------|----------------|
| 1   | Đinh Lê Phúc Duy      | 2210500 | Phân tích và thảo luận kết quả                   | 100%           |
| 2   | Nguyễn Hồ Phước Hiền  | 2211027 | Mô tả bài toán<br>Ràng buộc bổ sung              | 100%           |
| 3   | Phạm Thanh Phong      | 2212564 | Tiền xử lý dữ liệu<br>Áp dụng công cụ/thuật toán | 100%           |
| 4   | Nguyễn Võ Công Phương | 2212700 | Áp dụng công cụ/thuật toán                       | 100%           |
| 5   | Nguyễn Bá Việt Quang  | 2212741 | Áp dụng công cụ/thuật toán                       | 100%           |



## Mục lục

|          |                                                          |          |
|----------|----------------------------------------------------------|----------|
| <b>1</b> | <b>Giới thiệu</b>                                        | <b>1</b> |
| 1.1      | Định nghĩa bài toán                                      | 1        |
| 1.2      | Phương pháp tiếp cận                                     | 1        |
| <b>2</b> | <b>Thu thập dữ liệu và tiền xử lý dữ liệu</b>            | <b>2</b> |
| 2.1      | Mục đích                                                 | 2        |
| 2.2      | Các bước xử lý chính                                     | 3        |
| 2.3      | Kết quả đầu ra                                           | 4        |
| 2.4      | Thiết kế kho dữ liệu                                     | 5        |
| 2.4.1    | Mô hình dữ liệu (Star Schema)                            | 5        |
| 2.4.2    | Chi tiết thiết kế các bảng (Star Schema)                 | 6        |
| 2.4.3    | Phương án thay thế: Mô hình Snowflake Schema             | 7        |
| <b>3</b> | <b>Phương pháp đề xuất</b>                               | <b>8</b> |
| 3.1      | Mục đích                                                 | 8        |
| 3.2      | Các bước áp dụng chính                                   | 8        |
| 3.3      | Kết quả kỳ vọng                                          | 9        |
| <b>4</b> | <b>Kết quả đạt được</b>                                  | <b>9</b> |
| 4.1      | Phân tích OLAP                                           | 9        |
| 4.1.1    | Các view OLAP cốt lõi                                    | 9        |
| 4.1.2    | Diễn biến giá tổng hợp (Combined Price Trend)            | 10       |
| 4.1.3    | Xếp hạng khối lượng giao dịch năm 2025                   | 11       |
| 4.1.4    | Heatmap lợi suất tháng                                   | 12       |
| 4.1.5    | Tổng hợp các thao tác OLAP áp dụng                       | 12       |
| 4.2      | Data Visualization                                       | 13       |
| 4.2.1    | Biểu đồ giá đóng cửa của từng coin                       | 13       |
| 4.2.2    | Biểu đồ so sánh khối lượng giao dịch trung bình các coin | 17       |
| 4.2.3    | Biểu đồ so sánh hiệu suất đầu tư (Cumulative Growth)     | 18       |
| 4.2.4    | Biểu đồ biến động trượt (Rolling Volatility)             | 19       |
| 4.2.5    | Biểu đồ so sánh phân phối lợi nhuận giữa các coin        | 21       |
| 4.2.6    | Biểu đồ phân tích đột biến khối lượng (Volume Spike)     | 22       |
| 4.2.7    | Heatmap tương quan và đồng biến động                     | 24       |
| 4.3      | Data Mining                                              | 26       |
| 4.3.1    | Hồi quy tuyến tính (Linear Regression)                   | 26       |
| 4.3.2    | Gom cụm (K-Means Clustering)                             | 27       |



|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| 4.3.3    | Phát hiện bất thường (Anomaly Detection)                    | 29        |
| <b>5</b> | <b>Tích hợp Business Intelligence và Xây dựng Dashboard</b> | <b>31</b> |
| 5.1      | Hiện thực hóa mô hình dữ liệu trong Power BI                | 31        |
| 5.2      | Phân hệ 1 – Crypto Market Overview                          | 32        |
| 5.3      | Phân hệ 2 – Data Mining Insights                            | 34        |
| 5.4      | Tính năng OLAP Drill-down                                   | 35        |
| 5.5      | Ứng dụng Streamlit Dashboard                                | 36        |
| 5.6      | So sánh hai nền tảng                                        | 36        |
| <b>6</b> | <b>Demo hệ thống</b>                                        | <b>36</b> |
| 6.1      | Giao diện Dashboard Streamlit                               | 36        |
| 6.2      | Kịch bản Demo                                               | 41        |
| 6.3      | CSV mode – chạy không cần PostgreSQL                        | 42        |
| <b>7</b> | <b>Phân tích, thảo luận và hướng phát triển</b>             | <b>42</b> |
| 7.1      | Tổng quan kết quả chính                                     | 42        |
| 7.2      | Ý nghĩa và Ứng dụng                                         | 42        |
| 7.3      | Hạn chế nghiên cứu                                          | 43        |
| 7.4      | Hướng phát triển và đề xuất cải tiến                        | 44        |
|          | <b>Phụ lục</b>                                              | <b>44</b> |

# 1 Giới thiệu

## 1.1 Định nghĩa bài toán

Thị trường tiền mã hoá (cryptocurrency) đã trở thành một lớp tài sản mới có quy mô vốn hoá hàng nghìn tỷ USD, chịu ảnh hưởng trực tiếp từ chính sách tiền tệ, tin tức công nghệ và tâm lý nhà đầu tư toàn cầu. So với cổ phiếu truyền thống, dữ liệu crypto có đặc thù riêng: giao dịch liên tục 24/7, biến động giá rất mạnh (volatility cao gấp 5–10 lần thị trường chứng khoán), tập trung chủ yếu trên các sàn lớn như Binance, Coinbase, OKX, và phân hoá rõ rệt giữa các nhóm tài sản (Layer-1, Layer-2, Stablecoin, Meme, Payment). Bối cảnh đó khiến nhu cầu xây dựng một kho dữ liệu (Data Warehouse) chuyên biệt để hỗ trợ ra quyết định trở nên cấp thiết.

Báo cáo sử dụng dữ liệu lịch sử giá nến ngày (daily klines) của **10 đồng coin có vốn hoá lớn nhất theo Binance** gồm BTC, ETH, BNB, SOL, XRP, ADA, DOGE, TRX, DOT, MATIC. Dữ liệu được trích xuất trực tiếp từ Binance REST API endpoint `/api/v3/klines` [10], cung cấp các trường tiêu chuẩn: thời điểm mở/đóng phiên, OHLC (Open/High/Low/Close), khối lượng giao dịch (Volume) và khối lượng quy đổi USD. Mẫu dữ liệu kéo dài 730 ngày gần nhất cho mỗi coin (riêng MATIC có cửa sổ 2022–2024 vì Binance đã delist sau khi Polygon rebrand sang POL vào 09/2024), tổng cộng **7 300 dòng** trong Gold layer.

Mục tiêu của phân tích là (i) xây dựng pipeline ETL hoàn chỉnh đưa dữ liệu thô từ Binance vào Kho dữ liệu PostgreSQL chuẩn Star Schema, (ii) đo lường và so sánh hiệu suất, độ biến động, mức sụt giảm tối đa giữa các nhóm coin, (iii) áp dụng các kỹ thuật khai phá dữ liệu (hồi quy, phân cụm, phát hiện bất thường) để rút ra các tín hiệu định lượng, và (iv) trực quan hoá kết quả qua dashboard Power BI và Streamlit để hỗ trợ người dùng cuối ra quyết định. Các chỉ số trọng tâm bao gồm lợi suất (return\_pct), log return, độ biến động nội ngày, Z-Score rolling 30 ngày, market dominance và regime label (Bull/Bear/Sideways).

## 1.2 Phương pháp tiếp cận

Mục tiêu phân tích:

- **Ingestion 24/7:** Thu thập dữ liệu giá nến ngày của 10 đồng coin từ Binance REST API, đảm bảo idempotent (có thể chạy lại) và chịu lỗi mạng.
- **Chuẩn hoá và tải vào Staging:** Parse timestamp ms, ép kiểu NUMERIC(18,8) cho giá và NUMERIC(20,4) cho khối lượng, kiểm tra ràng buộc OHLC ( $low \leq open, close, high$ ).
- **Tính toán metrics ở tầng Transform:** Bao gồm return\_pct, log\_return, volatility (high–low), average\_price, volume\_usd, z\_score\_close (cửa sổ trượt 30 ngày), is\_anomaly (cờ  $|z| > 2$ ), volume\_rank và market\_dominance\_pct.
- **Mô hình hoá theo Star Schema** [12]: Bảng sự kiện fact\_market\_daily kết nối với 3 bảng chiều dim\_date, dim\_coin, dim\_category (4 nhóm: L1, L2, Meme, Payment kèm risk\_level).

- **Phân tích đa chiều OLAP [5]:** Xây dựng 3 view phân tích (lợi suất tuần theo category, bảng xếp hạng volume, danh sách phiên anomaly) phục vụ slice & dice và drill-down.
- **Khai phá dữ liệu (Data Mining):**
  - *Linear Regression*: Dự báo giá đóng cửa ngày T+1 với các feature OHLCV + lag.
  - *K-Means Clustering (k=3)*: Phân nhóm 10 coin theo hành vi rủi ro-lợi suất.
  - *Anomaly Detection*: Phát hiện các phiên có biến động cực đoan dựa trên Z-Score rolling 30 ngày.
- **Trực quan hoá đa nền tảng:** Dashboard Power BI cho lãnh đạo (chiến lược) và web app Streamlit (Plotly) cho người dùng cuối với 5 tab tương tác.
- **Quản trị dữ liệu & Orchestration:** Toàn bộ pipeline được điều phối bằng `run_pipeline.bat/.sh` (Python → psql → SQL → Views), có log tự động theo ngày và script `run_pipeline_rollback.bat` để rollback khi cần.

Hai phần trên định vị rõ: (i) nguồn dữ liệu Binance cùng đặc thù 24/7 và phương pháp chuẩn hoá để sẵn sàng cho Kho dữ liệu; (ii) các mục tiêu phân tích tập trung vào khai thác thông tin chi tiết, áp dụng các kỹ thuật học máy cơ bản và trực quan hoá tương tác để hỗ trợ ra quyết định trên thị trường tiền mã hoá đầy biến động.

## 2 Thu thập dữ liệu và tiền xử lý dữ liệu

Dữ liệu phân tích được trích xuất trực tiếp từ **Binance Public REST API** [10], endpoint `/api/v3/klines` cho phép tải về nền ngày của 10 cặp giao dịch (USDT) gồm BTC, ETH, BNB, SOL, XRP, ADA, DOGE, TRX, DOT, MATIC. Mỗi response trả về 13 trường tiêu chuẩn: `open_time`, `open`, `high`, `low`, `close`, `volume`, `close_time`, `quote_asset_volume`, `number_of_trades`, `taker_buy_base_asset_volume`, `taker_buy_quote_asset_volume` và `ignore_field`. Mỗi coin lấy 730 dòng dữ liệu lịch sử (cửa sổ 2 năm gần nhất, tính đến 2026-04-26), riêng MATIC chỉ có dữ liệu đến 09/2024 do bị Binance delist sau khi Polygon rebrand sang POL. Tổng cộng pipeline xử lý **~7 300 dòng dữ liệu thô**.

### 2.1 Mục đích

Script `scripts/1_fetch_binance.py` là một chương trình Python đảm nhận vai trò **ingestion layer** – thu thập dữ liệu giá crypto từ Binance API và chuẩn hoá thành các tệp CSV đồng nhất, sẵn sàng nạp vào tầng Staging của Kho dữ liệu. Cụ thể, chương trình đảm nhận các chức năng sau:

- Gọi Binance REST API có phân trang (limit 1000 nền/request) cho từng cặp coin/USDT.
- Chuẩn hoá timestamp Unix mili-giây sang `datetime` chuẩn ISO.

- Ép kiểu dữ liệu cho các cột giá (NUMERIC) và khối lượng (volume base/quote).
- Ghi ra các tệp `raw/<SYMBOL>_raw.csv` (idempotent, có thể chạy lại nhiều lần).
- Ghi log thành công/thất bại để phục vụ debug và audit.


## 2.2 Các bước xử lý chính

- Cấu hình ban đầu:** Đọc cấu hình từ tệp `.env` (`PG_HOST`, `PG_PORT`, `PG_DATABASE`, `PG_USER`, `PG_PASSWORD`).  
Danh sách 10 cặp giao dịch (TICKERS) được khai báo cứng trong script.
- Các hàm hỗ trợ trong `scripts/parsers.py`:** Chương trình tái sử dụng các hàm parser từ dự án trước:
  - `parse_number`: Chuẩn hoá chuỗi số có chứa dấu phẩy/chấm (ví dụ “63,770.00” → 63770.0).
  - `parse_date`: Chuẩn hoá chuỗi ngày sang `datetime`.
  - `parse_volume`: Quy đổi chuỗi “1.2M”, “900K” về số nguyên tuyệt đối.
- Gọi API và tải dữ liệu:** Với mỗi coin, chương trình gửi HTTP GET tới endpoint `/api/v3/klines` với tham số `symbol=<SYMBOL>USDT`, `interval=1d`, `limit=1000`. Tự động retry tối đa 3 lần khi lỗi mạng hoặc rate-limit (HTTP 429).
- Xử lý từng coin:** Sau khi nhận response JSON, chương trình:
  - Convert thời gian từ Unix milliseconds sang `open_time/close_time` kiểu `datetime`.
  - Ép kiểu NUMERIC(18,8) cho cột `open`, `high`, `low`, `close` và NUMERIC(20,4) cho `volume`, `quote_asset_volume`.
  - Tính các metric phái sinh ở tầng Transform (qua Pentaho hoặc SQL fallback):
    - **Return\_pct**:  $(Close - Open) / Open \times 100$
    - **Volume\_USD**:  $Close \times Volume$
    - **Volatility**:  $High - Low$
    - **Average\_price**:  $(High + Low) / 2$
    - **Log\_return**:  $\ln(Close) - \ln(Open)$
    - **Z\_score\_close**:  $(Close - \mu_{30}) / \sigma_{30}$  với cửa sổ rolling 30 ngày
    - **Is\_anomaly**:  $|z\_score| > 2$
  - Sắp xếp theo `open_time` tăng dần và lưu ra `raw/<SYMBOL>_raw.csv`.
- Tải lên Staging và Gold:** Sau khi 10 file CSV được sinh xong, pipeline gọi `psql \copy` (hoặc Pentaho job `01_clean.kjb`) để nạp vào `staging.ohlcv_raw`. Tiếp theo, script `02_transform_fallback.sql` (hoặc `02_transform.kjb`) tính các metric và đẩy vào `staging.fact_prep`. Cuối cùng `03_load_gold.sql` thực hiện `TRUNCATE + INSERT` vào `gold.fact_market_daily`.

## 2.3 Kết quả đầu ra

- 10 tệp CSV thô tại raw/<SYMBOL>\_raw.csv – đầu vào cho Pentaho/SQL.
- Bảng staging.ohlcv\_raw chứa ~7 300 dòng dữ liệu đã chuẩn hoá kiểu.
- Bảng gold.fact\_market\_daily (Star Schema) sẵn sàng cho OLAP và Data Mining.
- 3 OLAP view: v\_weekly\_return\_by\_category, v\_volume\_leaderboard, v\_top\_anomalies.

### Kiến trúc luồng ETL của CryptoDW – Binance → Staging → Gold




Hình 2.1: Kiến trúc luồng dữ liệu ETL và cấu trúc Schema của Kho dữ liệu Crypto



## 2.4 Thiết kế kho dữ liệu

### 2.4.1 Mô hình dữ liệu (Star Schema)

**Star Schema — Kho dữ liệu Crypto (gold layer)**



**Hình 2.2:** Mô hình kiến trúc Star Schema cho Kho dữ liệu Crypto

Dựa trên đặc thù dữ liệu thị trường tiền mã hoá (giao dịch 24/7, biến động cao, phân hoá nhóm rõ rệt) và nhu cầu phân tích đa chiều, nhóm lựa chọn kiến trúc **Star Schema** – mô hình được khuyến nghị cho data warehouse phân tích bởi Kimball [12] và được Inmon coi là “physical implementation tự nhiên” cho dimensional modeling [9]. Mô hình bao gồm một bảng *Fact Table* trung tâm **fact\_market\_daily** kết nối trực tiếp với ba bảng chiều *Dimension Tables*: **dim\_date**, **dim\_coin** và **dim\_category**.

Các lý do chính cho việc lựa chọn Star Schema thay vì Snowflake Schema bao gồm:

- **Tối ưu hoá hiệu suất truy vấn:** Star Schema giảm thiểu số JOIN. Với mục tiêu so sánh nhanh giữa các nhóm L1, L2, Meme, Payment, việc phi chuẩn hoá thông tin **category\_name** và **risk\_level** ngay trong **dim\_category** (không tách thêm bảng phụ) giúp truy vấn nhanh hơn.
- **Đơn giản hoá cho người dùng cuối:** Cấu trúc đơn giản giúp các công cụ BI (Power BI, Streamlit) dễ dàng mô hình hoá và tương tác.
- **Phù hợp quy mô dữ liệu:** Với 10 coin và 4 category, việc chuẩn hoá quá mức không mang lại lợi ích về lưu trữ.

## 2.4.2 Chi tiết thiết kế các bảng (Star Schema)

**Bảng 2.1:** Đặc tả bảng sự kiện: *gold.fact\_market\_daily*

| Tên trường           | Kiểu dữ liệu  | Ràng buộc | Mô tả                                       |
|----------------------|---------------|-----------|---------------------------------------------|
| date_id              | int           | PK, FK    | Khóa ngoại → dim_date                       |
| coin_id              | int           | PK, FK    | Khóa ngoại → dim_coin                       |
| open                 | numeric(18,8) |           | Giá mở phiên                                |
| high                 | numeric(18,8) |           | Giá cao nhất                                |
| low                  | numeric(18,8) |           | Giá thấp nhất                               |
| close                | numeric(18,8) |           | Giá đóng phiên                              |
| volume_base          | numeric(20,4) |           | Khối lượng đơn vị coin                      |
| volume_usd           | numeric(20,2) |           | $close \times volume\_base$                 |
| return_pct           | numeric(10,4) |           | $(close - open) / open \times 100$          |
| log_return           | numeric(10,6) |           | $\ln(close) - \ln(open)$                    |
| volatility           | numeric(18,8) |           | $high - low$                                |
| average_price        | numeric(18,8) |           | $(high + low) / 2$                          |
| z_score_close        | numeric(10,4) |           | Z-Score rolling 30 ngày                     |
| is_anomaly           | boolean       |           | $ z\_score  > 2$                            |
| volume_rank          | int           |           | RANK theo volume_usd mỗi ngày               |
| market_dominance_pct | numeric(6,3)  |           | $volume\_usd / SUM(\text{ngày}) \times 100$ |
| regime_label         | varchar(16)   |           | Bull / Bear / Sideways                      |

**Bảng 2.2:** Đặc tả bảng chiều: *gold.dim\_coin*

| Tên trường  | Kiểu dữ liệu | Ràng buộc | Mô tả                               |
|-------------|--------------|-----------|-------------------------------------|
| coin_id     | int          | PK        | Khoá đại diện                       |
| symbol      | varchar(10)  | NN, UQ    | Mã giao dịch (BTC, ETH, ...)        |
| full_name   | varchar(50)  |           | Tên đầy đủ (Bitcoin, Ethereum, ...) |
| launch_year | int          |           | Năm ra mắt                          |
| category_id | int          | FK        | → dim_category                      |

**Bảng 2.3:** Đặc tả bảng chiều: *gold.dim\_category*

| Tên trường    | Kiểu dữ liệu | Ràng buộc | Mô tả                    |
|---------------|--------------|-----------|--------------------------|
| category_id   | int          | PK        | Khoá nhóm                |
| category_name | varchar(20)  | NN        | L1 / L2 / Meme / Payment |
| risk_level    | varchar(10)  |           | Low / Mid / High         |


**Bảng 2.4:** Đặc tả bảng chiều thời gian: *gold.dim\_date*

| Tên trường   | Kiểu dữ liệu | Ràng buộc | Mô tả                |
|--------------|--------------|-----------|----------------------|
| date_id      | int          | PK        | Định dạng YYYYMMDD   |
| full_date    | date         | NN        | Ngày đầy đủ          |
| year         | int          |           | Năm                  |
| quarter      | int          |           | Quý (1–4)            |
| month        | int          |           | Tháng (1–12)         |
| month_name   | varchar(10)  |           | Jan, Feb, ...        |
| day_of_month | int          |           | Ngày trong tháng     |
| day_name     | varchar(10)  |           | Monday, Tuesday, ... |
| is_weekend   | bool         |           | Cờ cuối tuần         |

### 2.4.3 Phương án thay thế: Mô hình Snowflake Schema

Bên cạnh Star Schema, nhóm cũng xem xét mô hình **Snowflake Schema** (Lược đồ bông tuyết). Trong phương án này, bảng *dim\_coin* có thể được tách thêm các sub-dimension như *dim\_blockchain* (cơ chế đồng thuận: PoW, PoS) hoặc *dim\_protocol* (Bitcoin, EVM, Solana VM, ...).

**Snowflake Schema — Phương án chuẩn hoá (crypto)**



**Hình 2.3:** Mô hình kiến trúc Snowflake Schema (Chuẩn hoá)

Tuy nhiên với quy mô 10 coin, việc chuẩn hoá thêm sẽ làm tăng số JOIN và phức tạp hoá truy vấn mà không mang lại lợi ích về lưu trữ. Do đó nhóm vẫn chọn Star Schema làm thiết kế chính thức.

## 3 Phương pháp đề xuất

### 3.1 Mục đích

Hệ thống được thiết kế để **phân tích và khám phá dữ liệu thị trường Crypto** dựa trên các công cụ hiện đại và quy trình khoa học. Chương trình sử dụng ba kỹ thuật chính trong kho dữ liệu:

- **OLAP (Online Analytical Processing)** để tổng hợp, so sánh và quan sát xu hướng theo nhiều chiều (Thời gian, Danh mục coin, Chế độ thị trường).
- **Data Mining** để khai thác mẫu ẩn trong dữ liệu như dự đoán giá ngắn hạn, phân cụm hành vi rủi ro, và phát hiện các cú sốc thị trường.
- **Visualization** trên đa nền tảng (Power BI & Streamlit) để trực quan hóa dữ liệu, giúp người dùng nhận diện nhanh các điểm bất thường và cơ hội đầu tư.

### 3.2 Các bước áp dụng chính

- a) **Chuẩn bị dữ liệu đầu vào:** Dữ liệu được trích xuất từ PostgreSQL Gold Layer thông qua các View phân tích. Các trường dữ liệu bao gồm OHLCV kết hợp với các chỉ số tính toán sẵn như **Return\_pct**, **Z-Score** và các nhãn **Regime**.
- b) **Phân tích OLAP:** Phân tích đa chiều giúp tổng hợp dữ liệu theo từng danh mục:
  - **Slice & Dice:** Phân tích hiệu suất của từng Category (Layer 1, Meme) theo các khung thời gian khác nhau.
  - **Drill-down:** Khoan sâu từ dữ liệu tổng hợp nắm xuống biến động của từng phiên giao dịch cụ thể để tìm hiểu nguyên nhân bất thường.
  - **Pivot Analysis:** Bảng xếp hạng thanh khoản (Volume Leaderboard) và tỉ trọng thị trường (Dominance).
- c) **Khai phá dữ liệu (Data Mining):** Nhóm triển khai 3 kỹ thuật chính thông qua các Jupyter Notebook:
  - **Hồi quy tuyến tính (Linear Regression):** Dự báo giá  $T + 1$  của các đồng coin vốn hoá lớn.
  - **Gom cụm (Clustering) bằng K-Means:** Phân loại coin thành các nhóm Leaders, Altcoins và Speculative dựa trên độ biến động và lợi nhuận.
  - **Phát hiện bất thường (Anomaly Detection):** Sử dụng Z-Score rolling 30 ngày để gán cờ các phiên giao dịch cực đoan.
- d) **Trực quan hóa dữ liệu (Visualization):** Hệ thống cung cấp giao diện trực quan sinh động:

- **Streamlit Dashboard:** Cung cấp các biểu đồ động (Plotly) cho phép tương tác trực tiếp với Database.
- **Power BI Reports:** Báo cáo quản trị chuyên sâu với các biểu đồ Matrix, Treemap và Heatmap.

### 3.3 Kết quả kỳ vọng

- Hệ thống Pipeline ETL tự động đảm bảo dữ liệu luôn được cập nhật từ Binance.
- Kho dữ liệu chuẩn Star Schema tối ưu cho việc truy xuất thông tin nhanh chóng.
- Các mô hình khai phá dữ liệu cung cấp các chỉ báo định lượng có độ tin cậy cao ( $R^2 > 0.98$  cho mô hình hồi quy).
- Dashboard tương tác giúp người dùng không cần kiến thức kỹ thuật vẫn có thể theo dõi thị trường hiệu quả.

## 4 Kết quả đạt được

### 4.1 Phân tích OLAP


OLAP (Online Analytical Processing) [5] là kỹ thuật trung tâm để khai thác Kho dữ liệu theo nhiều chiều khác nhau. Trên `gold.fact_market_daily` kết hợp với 3 bảng chiều (`dim_date`, `dim_coin`, `dim_category`), nhóm xây dựng 3 view phân tích sẵn sàng cho dashboard và 3 báo cáo trực quan tổng hợp.

#### 4.1.1 Các view OLAP cốt lõi

- `gold.v_weekly_return_by_category`: Trung bình `return_pct` theo tuần và `category_name`, dùng cho biểu đồ heatmap so sánh hiệu suất giữa nhóm L1, L2, Meme và Payment.
- `gold.v_volume_leaderboard`: Bảng xếp hạng thanh khoản (`volume_usd`) toàn bộ kỳ, có `volume_rank` chốt mỗi ngày.
- `gold.v_top_anomalies`: Danh sách các phiên có `is_anomaly = TRUE` ( $|z\_score| > 2$ ), hỗ trợ cảnh báo sớm các sự kiện cực đoan.

#### 4.1.2 Diễn biến giá tổng hợp (Combined Price Trend)

**Combined Price Trend (Normalised to 1.0 at start) — 9 Coin \*MATIC bị loại do khung thời gian khác (delist 09/2024)**




**Hình 4.1:** Diễn biến giá đóng cửa của 10 coin (chuẩn hoá về 1.0 ở đầu kỳ)

Biểu đồ 4.1 chuẩn hoá giá đóng cửa về mức 1.0 vào ngày bắt đầu mẫu (27/04/2024) để có thể so sánh trực tiếp hiệu suất tích lũy giữa 9 coin. *MATIC bị loại khỏi biểu đồ tổng hợp này do khung thời gian khác biệt (Binance đã delist sau khi Polygon rebrand sang POL vào 09/2024)*. Có thể quan sát rõ:

- **Nhóm dẫn dắt:** BTC, BNB và TRX duy trì xu hướng tăng tương đối ổn định, kết thúc kỳ với mức tăng dương đáng kể.
- **Nhóm phân hoá mạnh:** XRP có cú bứt phá ngoạn mục cuối 2024 (sau pha tăng vọt liên quan ETF), trong khi DOT, ADA, MATIC liên tục downtrend, mất phần lớn giá trị so với đầu kỳ.
- **Tương quan ngành rõ rệt:** Pha sụt giảm chung cuối Q1/2025 thể hiện đặc tính đồng pha cao của crypto – một sự kiện vĩ mô (lãi suất, tin tức quy định) tác động đến gần như toàn thị trường.

#### 4.1.3 Xếp hạng khối lượng giao dịch năm 2025




**Hình 4.2:** Tổng khối lượng giao dịch năm 2025 (Billion USD) – xếp hạng top 10 coin

Biểu đồ 4.2 sử dụng aggregation SUM(volume\_usd) từ 01/01/2025 đến hết kỳ, nhóm theo symbol. Kết quả cho thấy sự phân hoá thành khoản cực mạnh:

- **BTC vẫn áp đảo** với khối lượng giao dịch quy đổi USD vượt trội, củng cố vị thế tài sản số “vàng kỹ thuật số”.
- **ETH và SOL** chia sẻ vị trí dẫn đầu nhóm Layer-1 thay thế.
- **Nhóm còn lại** (ADA, DOT, MATIC, TRX, ...) có thanh khoản thấp hơn 1–2 bậc magnitude, phản ánh xu hướng dòng tiền tập trung vào các coin có nền tảng vững chắc.

Đây cũng là cơ sở cho chiến lược “follow the volume” khi phát hiện breakout/breakdown – chỉ những tín hiệu giá trên BTC/ETH/SOL kèm volume spike mới đáng tin cậy.

#### 4.1.4 Heatmap lợi suất tháng



**Hình 4.3:** Heatmap lợi suất tháng (cumulative log-return  $\times 100$ ) theo coin

Biểu đồ 4.3 là dạng pivot trục Coin  $\times$  Month với giá trị là tổng `log_return` theo tháng (chuyển sang %). Màu xanh lá biểu thị tháng tăng giá, màu đỏ biểu thị tháng giảm. Đây chính là một thao tác OLAP **Pivot/Rotate** điển hình. Quan sát:

- Các tháng có cú bùng nổ chung (cả cột màu xanh sáng) thường trùng với các sự kiện vĩ mô tích cực: ETF được phê duyệt, Bitcoin halving, Fed cắt lãi suất.
- Các tháng giảm sâu đồng loạt (cả cột màu đỏ đậm) trùng với các sự kiện rủi ro hệ thống.
- DOGE và XRP thường xuyên có biên độ tháng lớn nhất (cả tăng lẫn giảm), khẳng định đặc tính “high-volatility / event-driven” của hai mã này.

Heatmap này cho phép thực hiện thao tác **Drill-down** đơn giản: từ một ô có biến động bất thường, người dùng có thể truy vấn xuống cấp ngày để tìm phiên cụ thể, sau đó cross-reference với **v\_top\_anomalies** để tìm nguyên nhân.

#### 4.1.5 Tổng hợp các thao tác OLAP áp dụng

- **Slice:** Lọc theo một ngày (WHERE date\_id = 20250115) hoặc một coin.




- **Dice:** Cắt theo tổ hợp nhiều chiều, ví dụ chỉ xem nhóm L1 trong Q2/2025.
- **Drill-down / Roll-up:** Từ mức năm → quý → tháng → ngày qua `dim_date`.
- **Pivot:** Xoay trục như Heatmap Coin  $\times$  Month ở hình 4.3.

## 4.2 Data Visualization

Phần này trình bày trực quan hoá hành vi giá, thanh khoản, độ biến động và phân phối lợi suất của 10 đồng coin trong Kho dữ liệu (BTC, ETH, BNB, SOL, XRP, ADA, DOGE, TRX, DOT, MATIC). Tất cả các biểu đồ được sinh trực tiếp từ `gold.fact_market_daily` thông qua script `tools/generate_report_images.py` sử dụng các thư viện chuẩn `matplotlib` và `seaborn` [13].

### 4.2.1 Biểu đồ giá đóng cửa của từng coin


#### 4.2.1.1 Bitcoin (BTC) – “vàng kỹ thuật số”



**Hình 4.4:** Diễn biến giá đóng cửa của BTC (USDT)

Biểu đồ 4.4 cho thấy BTC trải qua chu kỳ tăng trưởng mạnh sau Halving (04/2024), bứt phá vùng đỉnh cũ và lập đỉnh lịch sử mới. Sau giai đoạn phần khích này là một pha điều chỉnh sâu (drawdown  $\sim 50\%$ ) trước khi ổn định lại. Đặc trưng của BTC: *biến động lớn nhưng có tính chu kỳ rõ rệt*, là đại diện “low-vol” trong nhóm coin (so với altcoin còn lại) và đóng vai trò “tài sản trú ẩn” trong các giai đoạn rủi ro cao.


#### 4.2.1.2 Ethereum (ETH) – nền tảng smart contract dẫn đầu



Hình 4.5: Diễn biến giá đóng cửa của ETH (USDT)

Biểu đồ 4.5 cho thấy ETH có hiệu suất kém hơn BTC trong giai đoạn này: pha tăng trưởng yếu, drawdown tới ~63% từ đỉnh. Lý do chính là sự cạnh tranh từ các Layer-1 đối thủ (SOL) và sự hấp dẫn dòng tiền vào BTC ETF.

#### 4.2.1.3 Solana (SOL) – “ETH killer” với độ biến động cao



Hình 4.6: Diễn biến giá đóng cửa của SOL (USDT)

SOL (hình 4.6) là minh chứng cho “high risk – high reward”. Cú tăng vượt bậc cuối 2024 (theo đà meme coin trên hệ Solana) đi kèm drawdown ~70% sau khi pha hype kết thúc.


#### 4.2.1.4 XRP – biến động kiểu sự kiện (event-driven)



Hình 4.7: Diễn biến giá đóng cửa của XRP (USDT)

XRP (hình 4.7) thể hiện rõ kiểu biến động “event-driven”: giá đi ngang trong nhiều tháng, sau đó bùng nổ rất nhanh khi có tin tức (vụ kiện SEC, ETF). Pha tăng vọt cuối 2024 đưa XRP lên top coin có lợi suất tích lũy cao nhất trong nhóm phân tích.


#### 4.2.1.5 DOGE – meme coin điển hình




Hình 4.8: Diễn biến giá đóng cửa của DOGE (USDT)

DOGE (hình 4.8) là đại diện cho nhóm Meme với `risk_level = High`. Biên độ biến động cực lớn, drawdown lên tới ~81% từ đỉnh – minh họa rõ rủi ro tail của các coin có yếu tố “meme”.


#### 4.2.1.6 Cardano (ADA), Polkadot (DOT), Polygon (MATIC) – các altcoin underperformer



(a) ADA – drawdown  $\sim 80\%$



(b) DOT – drawdown  $\sim 89\%$



(c) MATIC – delist 09/2024 sau khi rebrand POL


**Hình 4.9:** Nhóm underperformer: ADA, DOT, MATIC

Cả ba mã (hình 4.9) đều rơi vào downtrend kéo dài. ADA và DOT mất 80–89% giá trị từ đỉnh; MATIC bị Binance delist sau rebrand POL nên dữ liệu chỉ kéo dài đến 09/2024. Đây là nhóm cần thận trọng nhất trong phân bổ danh mục.

#### 4.2.1.7 BNB, TRX – nhóm low-vol ổn định



(a) BNB




(b) TRX

**Hình 4.10:** Nhóm low-vol: BNB, TRX

BNB và TRX (hình 4.10) duy trì xu hướng tăng tương đối ổn định, biến động thấp nhất trong nhóm 10 coin. TRX đặc biệt nổi bật với lợi suất trung bình ngày dương rõ rệt và drawdown chỉ  $\sim 51\%$  – thấp nhất trong nhóm altcoin.

#### 4.2.2 Biểu đồ so sánh khối lượng giao dịch trung bình các coin



Hình 4.11: Khối lượng giao dịch trung bình hằng ngày (Million USD)

Biểu đồ 4.11 cho thấy sự phân cực thành khoản cực mạnh giữa 10 coin:


- **Nhóm 1 – Thanh khoản vượt trội:** BTC và ETH áp đảo, khối lượng giao dịch trung bình hàng ngày lên tới hàng tỷ USD.
- **Nhóm 2 – Thanh khoản tốt:** SOL, XRP, DOGE, BNB ở mức hàng trăm triệu USD.
- **Nhóm 3 – Thanh khoản thấp:** ADA, TRX, DOT, MATIC – thanh khoản tương đối hạn chế so với nhóm dẫn đầu.

Hệ luận quan trọng:

- *Tín hiệu giá có độ tin cậy khác nhau giữa các nhóm.* Một breakout trên BTC/ETH với volume spike đáng tin cậy hơn nhiều so với một biến động cùng biên độ trên DOT/MATIC.
- *Cần chuẩn hoá khi gom cụm.* Sự chênh lệch volume giữa BTC ( $\sim 10^{10}$ ) và DOT/MATIC ( $\sim 10^7$ ) là 3 bậc magnitude, nên K-Means buộc phải qua `StandardScaler` hoặc dùng  $\log_{10}(\text{volume\_usd})$  để tránh thiên

lệch.

### 4.2.3 Biểu đồ so sánh hiệu suất đầu tư (Cumulative Growth)



**Hình 4.12:** So sánh hiệu suất đầu tư – Cumulative Growth của \$1 đầu kỳ

Biểu đồ 4.12 chuẩn hoá giá trị của tất cả 10 coin về mức 1.0 vào đầu kỳ (27/04/2024). Đường biểu diễn cho thấy giá trị của \$1 đầu tư ban đầu sẽ thay đổi như thế nào theo thời gian:


- **Outperformer – XRP, TRX, BTC:** Có lợi suất trung bình ngày dương rõ rệt, kết thúc kỳ với mức tăng trưởng vượt trội. XRP đặc biệt nổi bật với cú bứt phá cuối 2024.
- **Trung tính – BNB:** Lợi suất trung bình ngày gần 0, đường cumulative growth dao động quanh mức 1.0.
- **Underperformer – ETH, SOL, DOGE:** Sau pha tăng đầu kỳ, đều rơi vào downtrend, kết thúc dưới mức 1.0.
- **Lỗ nặng – ADA, DOT, MATIC:** Mất 50–80% giá trị, đại diện cho nhóm rủi ro cao nhưng không có phần thưởng tương xứng trong giai đoạn này.

Khi kết hợp với biểu đồ thanh khoản (4.11), các cụm hiển hiện rõ:

- **Cụm 1 (High Return + High Volume):** BTC, XRP

- Cụm 2 (Low Return + High Volume): ETH, SOL
- Cụm 3 (Stable + Low/Mid Volume): BNB, TRX
- Cụm 4 (Negative Return + Low Volume): ADA, DOT, MATIC, DOGE


#### 4.2.4 Biểu đồ biến động trượt (Rolling Volatility)



**Hình 4.13:** Mức độ biến động giá – std log-return của sổ 20 ngày

Biểu đồ 4.13 thể hiện độ lệch chuẩn của log-return trên cửa sổ trượt 20 ngày, đo lường rủi ro ngắn hạn của từng coin:

- **Volatility Clustering:** Hiện tượng “rủi ro tụ lại” rất rõ – khi một coin bắt đầu biến động mạnh, nó có xu hướng duy trì trạng thái rủi ro cao trong nhiều tuần (ví dụ giai đoạn cuối Q1/2025 cả thị trường cùng biến động mạnh).
- **Phân nhóm khẩu vị rủi ro:**
  - *Rủi ro cao thường trực:* ADA, DOGE, DOT, SOL gần như luôn nằm ở nửa trên biểu đồ với std hằng ngày 4–5%.
  - *Rủi ro thấp ổn định:* BTC, BNB, TRX có std hằng ngày chủ yếu 2–3%, nửa thấp hơn nhóm còn lại.
  - *Rủi ro thay đổi theo sự kiện:* XRP có giai đoạn biến động cực cao quanh các sự kiện kiện tụng/ETF, sau đó trở lại mức trung bình.



**Hình 4.14:** Mức độ biến động giá – std log-return của sổ 60 ngày


Biểu đồ 4.14 dùng cửa sổ trượt 60 ngày, loại bỏ nhiễu ngắn hạn để thể hiện cấu trúc rủi ro dài hạn:

- Nhóm nền tảng (BTC, BNB, TRX) có đường biểu diễn ổn định ở vùng thấp – xác nhận đặc tính “low structural risk”.
- Nhóm altcoin biến động cao (ADA, DOGE, DOT) duy trì đường biểu diễn ở vùng cao trong hầu hết kỳ.

Đây là feature quan trọng cho việc gom cụm bằng K-Means – thay vì dùng volatility 20 ngày dễ bị nhiễu, dùng volatility 60 ngày giúp K-Means nhận diện chính xác hơn các nhóm có đặc tính rủi ro tương đồng.



#### 4.2.5 Biểu đồ so sánh phân phối lợi nhuận giữa các coin




**Hình 4.15:** Phân phối log-return hàng ngày của 10 coin

Biểu đồ 4.15 thể hiện phân phối log-return hàng ngày. Mỗi hộp (box) chứa 50% số ngày giao dịch điển hình; các chấm tròn ngoài râu (whisker) là các phiên *outlier* cần được phát hiện bằng Anomaly Detection.

- **Trung vị – hiệu suất kỳ vọng:** XRP và TRX có median dương rõ rệt; BTC, BNB gần 0; ETH, SOL, ADA, DOT, MATIC có median âm.
- **Độ rộng hộp – biến động:** ADA, DOGE, SOL có hộp rộng nhất, là nhóm rủi ro cao. BTC, BNB, TRX có hộp hẹp nhất.
- **Outlier:** Tất cả coin đều có outlier đối xứng cả hai phía, nhưng DOGE và XRP có nhiều outlier nhất, phù hợp với đặc tính “event-driven”.

#### 4.2.6 Biểu đồ phân tích đột biến khối lượng (Volume Spike)




Hình 4.16: *Volume Spike vs Daily Return*

Biểu đồ 4.16 thể hiện mối quan hệ giữa khối lượng giao dịch (trục X, đơn vị tỷ USD) và lợi nhuận % (trục Y). Một phiên được đánh dấu là Volume Spike (chấm đỏ) khi  $\text{volume\_usd} > 2 \times \text{rolling\_median\_20d}$ .


- **Phiên thường (xanh):** Tập trung ở phía trái với volume thấp và return dao động hẹp ( $\pm 5\%$ ) – trạng thái cân bằng của thị trường.
- **Phiên Volume Spike (đỏ):** Phân bố ở phía phải, lệch về biên trên hoặc biên dưới của trục Y. Ít phiên Spike kết thúc với return  $\sim 0$ .

Điều này khẳng định: *volume bùng nổ là tín hiệu rõ của biến động giá lớn, theo cả hai chiều.*



Hình 4.17: So sánh  $|Return|$  trung bình: Spike vs Non-Spike

Biểu đồ 4.17 là kết luận định lượng: với mọi coin, cột màu cam ( $|Return|$  trong ngày Spike) luôn cao gấp **2–3 lần** cột xanh (Non-Spike). Mỗi quan hệ này phổ quát, không phụ thuộc vào coin cụ thể.



Hình 4.18: Số ngày Volume Spike theo coin


Biểu đồ 4.18 cho thấy số phiên Volume Spike trên 730 ngày của mỗi coin, dao động trong khoảng 50–80 phiên ( $\sim 7\text{--}11\%$ ). DOGE và XRP có số phiên spike cao hơn, phù hợp với đặc tính event-driven của hai mã này.

**Quy tắc giao dịch định lượng rút ra:**

- *Breakout xác nhận*: Một phiên có  $return > +5\%$  chỉ được coi là tín hiệu phá vỡ đáng tin khi đi kèm Volume Spike.

- *Breakdown xác nhận*: Tương tự với phiên giảm sâu  $return < -5\%$ .
- *Feature dự báo*: Cờ `is_spike` là feature có giá trị cao cho mô hình hồi quy/phân loại biến động.

#### 4.2.7 Heatmap tương quan và đồng biến động




Hình 4.19: Heatmap tương quan log-return giữa 10 coin

Biểu đồ 4.19 thể hiện hệ số tương quan Pearson giữa các chuỗi log-return:

- **Tương quan dương rất mạnh** ( $\rho > 0.8$ ): Hầu hết các cặp altcoin Layer-1 (ETH-SOL, ETH-ADA, SOL-DOT, ...) cho thấy thị trường crypto vận động đồng pha cao – khi BTC tăng, các altcoin đa phần cũng tăng theo.
- **BTC-altcoin** ( $\rho \approx 0.7 - 0.8$ ): BTC đóng vai trò “benchmark” của toàn thị trường.
- **MATIC tách biệt**: Do dữ liệu chỉ đến 09/2024, tương quan với các coin khác thấp hơn rõ rệt.

**Hệ luận về đa dạng hoá [3]:** Trong phạm vi 10 coin top, lợi ích đa dạng hoá nội bộ rất hạn chế – gần như tất cả đều biến động cùng chiều. Để thực sự giảm rủi ro danh mục, nhà đầu tư cần kết hợp với các tài sản ngoài crypto (vàng, trái phiếu, cổ phiếu) – nguyên lý Modern Portfolio Theory [4].

### Heatmap Đồng biến động (Hiệp phương sai Log-Return)



Hình 4.20: Heatmap đồng biến động (hiệp phương sai log-return)

Biểu đồ 4.20 thể hiện ma trận hiệp phương sai (covariance) – khác với tương quan, các giá trị này phản ánh *độ lớn thực tế* của biến động:

- **Đường chéo (phương sai):** Cao nhất ở ADA, DOGE, DOT (rủi ro nội tại lớn). Thấp nhất ở BTC và TRX.
- **Ngoài đường chéo:** Tất cả đều dương cao, cho thấy rủi ro danh mục crypto khó giảm chỉ bằng cách đa dạng hoá nội ngành – một hệ quả định lượng quan trọng cho việc xây dựng portfolio.

Hai heatmap này là **nền tảng toán học** cho thuật toán K-Means gom cụm: các coin có hiệp phương sai cao

và cùng dấu sẽ được gom vào cùng cluster, tự động phân biệt nhóm low-vol vs high-vol mà không cần gắn nhãn thủ công.

## 4.3 Data Mining

Phần này áp dụng ba kỹ thuật khai phá dữ liệu trên `gold.fact_market_daily` [6]: hồi quy tuyến tính (Linear Regression) để dự báo giá ngắn hạn, gom cụm K-Means để phân nhóm hành vi 10 coin, và phát hiện bất thường (Anomaly Detection) bằng Z-Score rolling. Việc lựa chọn ba kỹ thuật cơ bản này phù hợp với tính chất bài toán có  $n = 10$  đối tượng và chuỗi thời gian 730 điểm — một phạm vi mà các mô hình phức tạp hơn (Deep Learning) sẽ overfitting nghiêm trọng [11].

### 4.3.1 Hồi quy tuyến tính (Linear Regression)

Mục tiêu là xây dựng mô hình dự báo giá đóng cửa của các đồng coin với hai cách tiếp cận khác nhau.

#### 4.3.1.1 Dự báo giá Close ngày $T+1$ (mô hình thực tế)

Dùng OHLCV của ngày  $T$  cộng các lag feature để dự báo `close_next_day`:

$$Close_{T+1} = \alpha_0 + \alpha_1 Open_T + \alpha_2 High_T + \alpha_3 Low_T + \alpha_4 Close_T + \alpha_5 Volume_T + \alpha_6 MA7_T + \alpha_7 Z_T$$

**Phương pháp:** Time-based split 80/20 (không shuffle để tránh *data leakage* [11]). Train trên 535 điểm đầu, test trên 135 điểm cuối.

**Kết quả thực nghiệm** (chạy trên Gold layer, tổng hợp trong bảng 4.1):

**Bảng 4.1:** Hiệu suất Linear Regression dự báo  $Close_{T+1}$  trên 10 coin (split 80/20)

| Coin  | $R^2$  | MSE                   | $\alpha_0$ | $\alpha_4$ (Close) | $\alpha_5$ (Vol) | $\alpha_7$ (Z) |
|-------|--------|-----------------------|------------|--------------------|------------------|----------------|
| BTC   | 0.9639 | $3.68 \times 10^6$    | 1235.5     | 0.7840             | -0.0054          | -1156.8        |
| ETH   | 0.9689 | 7 289                 | 22.4       | 0.7211             | -0.0017          | -43.9          |
| BNB   | 0.9800 | 326.5                 | 4.8        | 0.8124             | -0.0021          | -12.5          |
| SOL   | 0.9659 | 17.63                 | 0.78       | 0.7651             | -0.0008          | -3.42          |
| XRP   | 0.9619 | 0.00335               | 0.011      | 0.8089             | -0.0011          | -0.058         |
| ADA   | 0.9468 | 0.000212              | 0.003      | 0.7892             | -0.0014          | -0.014         |
| DOGE  | 0.9468 | $2.10 \times 10^{-5}$ | 0.0009     | 0.7754             | -0.0017          | -0.0049        |
| TRX   | 0.9436 | $1.50 \times 10^{-5}$ | 0.001      | 0.7423             | -0.0008          | -0.0043        |
| DOT   | 0.9205 | 0.00873               | 0.022      | 0.7521             | -0.0019          | -0.121         |
| MATIC | 0.9606 | 0.000544              | 0.005      | 0.8043             | -0.0017          | -0.025         |

### Phân tích kết quả:

- Mức độ chính xác:**  $R^2$  dao động **0.92–0.98** với median  $\sim 0.96$ . Đây là mức cao, nhưng cần *cảnh giác*:  $R^2$  cao chủ yếu phản ánh tính *quán tính giá* (giá hôm nay là chỉ báo mạnh cho giá ngày mai) chứ không phải khả năng dự báo *biến động* (đại lượng nhà đầu tư thực sự cần).

- **Coin dễ dự báo nhất là BNB** ( $R^2 = 0.98$ ) – do biên độ biến động ngày thấp nhất trong nhóm. **Khó dự báo nhất là DOT** ( $R^2 = 0.92$ ) – nhất quán với việc DOT có drawdown sâu nhất ( $-89\%$ ).
- **Hệ số  $\alpha_4$  (Close hôm nay) luôn dominant** (0.74–0.81), khẳng định Close là feature quan trọng nhất, đúng kỳ vọng cho chuỗi thời gian random-walk-like.
- **Hệ số  $\alpha_7$  (Z-Score) luôn âm** – phù hợp lý thuyết *mean reversion*: khi giá vượt xa trung bình lịch sử ( $Z > 0$ ), kỳ vọng có điều chỉnh giảm trong ngày kế tiếp [7]. Đây là phát hiện có ý nghĩa kinh tế chứ không chỉ là artifact thống kê.

#### Hạn chế của Linear Regression cho chuỗi giá crypto:

- $R^2$  cao không đồng nghĩa hữu ích. Mô hình chủ yếu dự báo  $Close_{T+1} \approx Close_T$ , là một benchmark naïve. Để đánh giá đúng phải so với “persistence model” và đo bằng *directional accuracy* (% đoán đúng chiều).
- **Giả định linearity và stationary** không phù hợp với thị trường crypto vốn phi tuyến và non-stationary. Các mô hình ARIMA/GARCH [8] hoặc mạng LSTM sẽ phù hợp hơn cho mở rộng tương lai.

#### 4.3.2 Gom cụm (K-Means Clustering)


Mỗi đồng coin được biểu diễn bằng vector đặc trưng 4 chiều: **return\_avg** (lợi suất trung bình ngày), **vol\_avg** (độ biến động ngày), **log10(volume\_usd\_avg)** (thanh khoản), **max\_drawdown** (rủi ro đuôi). Vector được chuẩn hoá bằng **StandardScaler** [14] trước khi đưa vào K-Means.

##### 4.3.2.1 Chọn số cụm $k$ – Validation

Để chọn  $k$  một cách khách quan, nhóm chạy K-Means với  $k = 2, 3, 4, 5, 6$  và đo hai chỉ số: *Inertia* (tổng SSE trong cụm, càng nhỏ càng tốt) và *Silhouette score* (càng gần 1 càng tốt) [1]. Kết quả ở bảng 4.2 và Hình 4.21.

**Bảng 4.2:** Kết quả validation K-Means trên 10 coin

| $k$        | 2            | 3     | 4     | 5     | 6     |
|------------|--------------|-------|-------|-------|-------|
| Inertia    | 18.24        | 12.34 | 8.82  | 5.51  | 3.17  |
| Silhouette | <b>0.374</b> | 0.281 | 0.236 | 0.256 | 0.230 |




Hình 4.21: Validation K-Means: Inertia (đỏ) và Silhouette (xanh) theo k

#### Diễn giải kết quả validation:

- Silhouette cao nhất tại  $k = 2$  (0.374) – về mặt thống kê thuần túy, K-Means “muốn” chia 10 coin thành *hai nhóm*: BTC + tài sản tăng trưởng tốt vs phần còn lại.
- Tuy nhiên,  $k = 2$  **quá thô** cho mục đích báo cáo: nó gộp BTC với SOL/XRP – mặc dù 2 nhóm này có hành vi rủi ro rất khác (BTC drawdown  $-49\%$ , SOL drawdown  $-70\%$ ).
- $k = 3$  (silhouette 0.281) cân bằng giữa độ tách cụm và *khả năng diễn giải nghiệp vụ*: cho ra ba nhóm mang ý nghĩa thực tế Leaders / Mid-cap / Speculative – phù hợp với phân loại risk-level đã có sẵn trong `dim_category` (Low / Mid / High).
- Nhóm chọn  $k = 3$  vì ưu tiên *actionability cho người dùng cuối* hơn là tối đa hoá silhouette tuyệt đối – một quyết định thường gặp khi áp dụng K-Means trong domain finance [2].



#### 4.3.2.2 Kết quả K-Means $k = 3$



Hình 4.22: K-Means clustering ( $k = 3$ ) cho 10 đồng coin – chiều PCA 2D

Bảng 4.3: Đặc trưng từng cluster sau khi K-Means hội tụ

| Cluster           | Coin                  | Vol/ngày | Drawdown      | Tính chất                   |
|-------------------|-----------------------|----------|---------------|-----------------------------|
| 2 – “Leaders”     | BTC, BNB, TRX         | 2.4–3.4% | –49% đến –55% | Low-vol, ổn định            |
| 0 – “Mid-cap”     | ETH, SOL, XRP         | 3.7–4.3% | –63% đến –70% | Tăng trưởng kèm rủi ro vừa  |
| 1 – “Speculative” | ADA, DOGE, DOT, MATIC | 4.3–4.9% | –76% đến –89% | Biến động cao, drawdown sâu |

#### Hệ luận đầu tư:

- Tỷ trọng cao nhất nên đặt vào cụm Leaders (BTC, BNB, TRX) – thoả khẩu vị “ăn chắc, mặc bền”.
- Tỷ trọng trung bình cho cụm Mid-cap (ETH, SOL, XRP) – đặt cược vào hệ sinh thái smart contract.
- Tỷ trọng nhỏ và mang tính đầu cơ với cụm Speculative – chỉ phù hợp với nhà đầu tư chấp nhận rủi ro tail rất lớn.

#### 4.3.3 Phát hiện bất thường (Anomaly Detection)

**Phương pháp:** Z-Score được tính riêng cho từng coin với cửa sổ rolling 30 ngày để kiểm soát tính phi dừng (non-stationarity) của chuỗi giá [8]:

$$z_t = \frac{Close_t - \mu_{30}(Close)}{\sigma_{30}(Close)}, \quad \text{phiên là anomaly} \iff |z_t| > 2$$

#### Kết quả tổng hợp:

**Bảng 4.4:** Tỷ lệ phiên anomaly trên từng coin (730 ngày)

| Coin | Số phiên | Tỷ lệ (%) | Coin  | Số phiên | Tỷ lệ (%) |
|------|----------|-----------|-------|----------|-----------|
| BTC  | 89       | 12.19     | ADA   | 87       | 11.92     |
| ETH  | 85       | 11.64     | DOGE  | 84       | 11.51     |
| BNB  | 87       | 11.92     | TRX   | 107      | 14.66     |
| SOL  | 86       | 11.78     | DOT   | 77       | 10.55     |
| XRP  | 82       | 11.23     | MATIC | 90       | 12.33     |

Tỷ lệ anomaly trung bình  $\sim 12\%$ , cao gấp  $\sim 2.5$  lần so với giả định lý thuyết về phân phối chuẩn ( $|z| > 2 \Rightarrow 4.55\%$ ). Điều này khẳng định chuỗi giá crypto có phân phối *fat-tail*, không tuân theo phân phối Gauss [7].

#### 4.3.3.1 Case study – Anomaly có ý nghĩa kinh tế

Để chứng minh các phiên anomaly không chỉ là noise thống kê, nhóm đối chiếu top-5 phiên có  $|z|$  lớn nhất của BTC và DOGE với các sự kiện vĩ mô (bảng 4.5).

**Bảng 4.5:** Top phiên anomaly và sự kiện vĩ mô tương ứng

| Coin | Ngày       | Close (USD) | Return  | Sự kiện vĩ mô tương ứng                    |
|------|------------|-------------|---------|--------------------------------------------|
| BTC  | 2024-11-11 | 88 648      | +9.80%  | Trump thắng cử (5/11) – BTC rally vượt 89k |
| BTC  | 2025-07-10 | 116 010     | +4.20%  | Spot BTC ETF đạt AUM kỷ lục                |
| BTC  | 2026-02-05 | 62 910      | −15.10% | Fed pause cắt lãi suất + tin tức trade war |
| DOGE | 2024-11-10 | 0.28        | +23.82% | Hiệu ứng “Trump + Musk DOGE meme”          |
| DOGE | 2024-11-11 | 0.35        | +23.50% | DOGE rally tiếp ngày thứ 2 sau Trump win   |
| ETH  | 2024-05-20 | 3 662       | +17.59% | SEC chuẩn bị duyệt Spot ETH ETF (23/5)     |
| ETH  | 2025-05-08 | 2 207       | +19.79% | Pectra upgrade ETH mainnet hoạt động       |

**Phân tích:** Tất cả các phiên anomaly liệt kê đều có *nguyên nhân kinh tế hoặc chính trị rõ ràng*, không phải lỗi dữ liệu hay nhiễu thống kê. Đặc biệt:

- Cụm DOGE 10–11/11/2024 (+23.82% rồi +23.50%) thể hiện hiệu ứng *volatility clustering* – một phiên cực đoan thường kéo theo phiên cực đoan khác.
- BTC giảm −15.10% ngày 05/02/2026 cho thấy crypto vẫn nhạy cảm cao với chính sách tiền tệ Mỹ – một phát hiện quan trọng cho nhà đầu tư danh mục.

#### Ứng dụng thực tiễn:

- *Cảnh báo sớm:* Khi  $|z_t| > 2$  kết hợp Volume Spike, hệ thống nên gửi alert ngay (đã tích hợp trong tab Anomaly Detection của Streamlit Dashboard).
- *Lọc dữ liệu:* Các phiên anomaly có thể được winsorize trước khi tính Sharpe ratio, VaR để tránh bị méo [4].
- *Backtest:* Khi xây dựng chiến lược giao dịch, các phiên anomaly là test case quan trọng – hệ thống stop-loss phải xử lý đúng các sự kiện cực đoan này.

## 5 Tích hợp Business Intelligence và Xây dựng Dashboard


Sau khi hoàn tất quá trình ETL và khai phá dữ liệu, nhóm thực hiện xây dựng lớp trình bày (Presentation Layer) sử dụng song song hai nền tảng: **Microsoft Power BI Desktop** (cho đối tượng quản trị / lãnh đạo) và **Streamlit** (cho phân tích viên kỹ thuật). Mục tiêu là chuyển đổi kết quả phân tích từ SQL và Python thành hệ thống báo cáo tương tác phục vụ ra quyết định [12].

### 5.1 Hiện thực hóa mô hình dữ liệu trong Power BI

Dữ liệu từ Gold Layer trong PostgreSQL được nạp vào Power BI thông qua hai phương án:

- **DirectQuery / Import qua Npgsql ODBC** – chế độ production khi PostgreSQL đã được triển khai.
- **CSV Import** qua script `tools/export_gold_for_powerbi.py` – chế độ thử nghiệm nhanh, không cần PostgreSQL. Script này xuất 4 tệp CSV (`fact_market_daily.csv`, `dim_coin.csv`, `dim_date.csv`, `dim_category.csv`) tương ứng các bảng trong Star Schema.

Trong Model View của Power BI, kiến trúc Star Schema được hiện thực hóa với bảng sự kiện trung tâm `fact_market_daily` kết nối với ba bảng chiều qua quan hệ *many-to-one* (Hình 5.1).




Hình 5.1: Power BI Model View – Star Schema với 3 active relationships

Việc đánh dấu `dim_date` bằng *Mark as date table* cho phép Power BI tự động sinh Date Hierarchy (Year → Quarter → Month → Day), phục vụ cho thao tác Drill-down – một tính năng nền tảng của OLAP [5].

## 5.2 Phân hệ 1 – Crypto Market Overview

Phân hệ này phục vụ nhu cầu theo dõi tổng quan thị trường, dành cho lãnh đạo và nhà đầu tư cá nhân.



Hình 5.2: Power BI Dashboard – Crypto Market Overview

Dashboard này (Hình 5.2) gồm bốn vùng visual chính:


- **KPI Cards (hàng đầu):** 5 số liệu tổng quan – Total Volume USD (~ \$3,933B), Avg Daily Return (+0.053%), Anomaly Days (874 phiên, ~ 12%), Bull/Bear Days, và Coins Selected. Dùng DAX measure như:

```
Total Volume USD = SUM(fact_market_daily[volume_usd])
Anomaly Days = CALCULATE(COUNTROWS(fact_market_daily),
    fact_market_daily[is_anomaly] = TRUE())
```

- **Daily Close Price (line chart):** Top-5 coin theo volume, chuẩn hoá về 1.0 đầu kỳ – cho phép so sánh hiệu suất tích lũy trực quan.
- **Market Dominance (donut):** Tỷ trọng volume\_usd của từng coin – BTC chiếm ~ 25%, ETH ~ 20%, phần còn lại chia đều.
- **Volume Leaderboard (horizontal bar):** Xếp hạng thanh khoản trung bình ngày – giúp xác định coin nào có liquidity đủ cho giao dịch khối lượng lớn.

### 5.3 Phân hệ 2 – Data Mining Insights

Phân hệ này trực quan hoá kết quả của các kỹ thuật khai phá dữ liệu (mục 4.3), phục vụ phòng phân tích định lượng.




Hình 5.3: Power BI Dashboard – Data Mining Insights

Dashboard này (Hình 5.3) gồm bốn visual:

- **Risk-Return Scatter (scatter plot):** Trục X = Volatility (std return), trục Y = Mean Return, kích thước bubble = Volume, màu = Category. Visual này tái hiện kết quả K-Means clustering ở mục 4.3.2 trong môi trường tương tác – người dùng có thể click vào một bubble để filter các visual khác.
- **Regime Distribution (stacked bar):** Tỷ lệ ngày Bull/Sideways/Bear cho từng coin. Màu xanh lá = Bull, vàng = Sideways, đỏ = Bear.
- **Top Anomalies per Coin (horizontal bar):** Số phiên có  $|z\_score| > 2$  – cho thấy TRX là coin có nhiều anomaly nhất (107 phiên).
- **Top-10 Extreme Anomalies (table):** Danh sách phiên cực đoan nhất theo  $|z|$  – tham chiếu trực tiếp gold.v\_top\_anomalies view.

## 5.4 Tính năng OLAP Drill-down

Đặc trưng quan trọng của Power BI là khả năng **drill-down** dọc theo Date Hierarchy của `dim_date` [5]. Hình 5.4 minh họa thao tác drill-down 3 cấp cho BTC: từ tổng hợp năm → quý → tháng.



Hình 5.4: OLAP Drill-down: Year → Quarter → Month cho BTC

Quy trình thao tác:

1. **Level 1 (Year):** Bar chart hiển thị tổng `return_pct` mỗi năm.
2. **Level 2 (Quarter):** Click chuột phải → Drill down vào năm có biến động lớn nhất – bar chart đổi sang Q1/Q2/Q3/Q4.
3. **Level 3 (Month):** Tiếp tục drill down vào quý có anomaly cao nhất – bar chart đổi sang từng tháng, lộ ra tháng cụ thể có sự kiện.

Đây chính là chuỗi thao tác OLAP cốt lõi (Drill-down + Roll-up) mà Kimball mô tả là “the killer feature of

*dimensional modeling*” [12].

## 5.5 Ứng dụng Streamlit Dashboard

Bên cạnh Power BI, nhóm còn xây dựng một dashboard tương tác bằng Python Streamlit (`streamlit_crypto.py`). Ứng dụng kết nối trực tiếp PostgreSQL hoặc CSV (qua wrapper `streamlit_crypto_csv.py`), cho phép người dùng tùy chỉnh tham số và quan sát các biểu đồ Plotly trên nền tảng Web – chi tiết xem chương Demo (mục 6).

## 5.6 So sánh hai nền tảng

**Bảng 5.1:** So sánh Power BI và Streamlit cho dự án CryptoDW

| Khía cạnh            | Power BI Desktop          | Streamlit                    |
|----------------------|---------------------------|------------------------------|
| Đối tượng người dùng | Lãnh đạo, không-coder     | Phân tích viên kỹ thuật      |
| Học cách dùng        | Drag & drop, dễ           | Cần biết Python              |
| Tùy biến chuyên sâu  | Hạn chế (DAX)             | Toàn quyền (Python + Plotly) |
| Triển khai chia sẻ   | Power BI Service (cloud)  | Streamlit Cloud / Docker     |
| Chi phí licence      | Cần PRO licence cho share | Miễn phí mã nguồn mở         |
| Refresh dữ liệu      | Manual / Scheduled        | Realtime khi có request      |

Việc cung cấp song song cả hai nền tảng đáp ứng được nhu cầu đa tầng trong tổ chức: lãnh đạo dùng Power BI để xem báo cáo tổng hợp định kỳ, trong khi phân tích viên dùng Streamlit để khai thác dữ liệu chuyên sâu [17].


## 6 Demo hệ thống

Nhóm xây dựng hệ thống Dashboard tương tác giúp người dùng theo dõi và phân tích thị trường Crypto. Hệ thống được triển khai trên nền tảng *Streamlit* (Python + Plotly), kết nối trực tiếp với PostgreSQL Database (Gold Layer) hoặc đọc trực tiếp từ các tệp CSV xuất từ tầng Gold (chế độ “CSV mode” qua `streamlit_crypto_csv.py`).


### 6.1 Giao diện Dashboard Streamlit

Giao diện được thiết kế theo phong cách Dark Theme với 5 tab chức năng chính tương ứng với năm góc nhìn phân tích khác nhau.






Hình 6.1: Tab **Overview** – Tổng quan thị trường: KPI bar (Total Volume, Avg Daily Return, Anomaly Days, Bull/Bear Days, Coins Selected) và Daily Close Price chart cho toàn bộ 10 đồng coin.




Hình 6.2: Tab *Price & Volume* – Candlestick chart kèm volume bars cho từng coin, có Return Distribution histogram và Volatility timeline.



Hình 6.3: Tab *Anomaly Detection* – Z-Score rolling 30 ngày với các phiên anomaly ( $|z| > 2$ ) đánh dấu đỏ, kèm *Anomaly Rate per Coin* và bảng *Top 10 Extreme Anomalies*.



Hình 6.4: Tab **OLAP Views** – Weekly Avg Return facet theo Category (L1/L2/Meme/Payment), Correlation Heatmap và Volume Leaderboard.



Hình 6.5: Tab *Data Explorer* – Bảng dữ liệu thô với filter theo Regime/Anomaly, hỗ trợ download CSV.

## 6.2 Kịch bản Demo

Quy trình demo hệ thống bao gồm 4 bước chính:

- Cập nhật dữ liệu:** Chạy `run_pipeline.bat` (Windows) hoặc `run_pipeline.sh` (Linux/WSL) để kích hoạt luồng ETL: Binance API → Staging → Transform → Gold Layer → refresh OLAP views.
- Phân tích OLAP:** Sử dụng tab Overview và Price & Volume để slice/dice theo coin và khoảng thời gian; quan sát Market Dominance, Regime Distribution và Volume Leaderboard.
- Khai phá dữ liệu:** Truy cập tab Anomaly Detection để xem các phiên có  $|z\_score| > 2$ . Mở Jupyter notebooks trong thư mục `ai/` để xem kết quả Linear Regression, K-Means clustering và Anomaly Detection ở mức code chi tiết.
- Báo cáo quản trị:** Mở Power BI Dashboard (`bi/Crypto_Dashboard.pbix`) để xem báo cáo tổng hợp theo quý và năm.

## 6.3 CSV mode – chạy không cần PostgreSQL

Để hỗ trợ giảng viên/đồng nghiệp chạy thử nhanh mà không cần cài đặt PostgreSQL, nhóm bổ sung script `streamlit_crypto_csv.py` đọc trực tiếp 4 tệp CSV xuất từ tầng Gold (sinh bởi `tools/export_gold_for_powerbi.py`). Câu lệnh chạy:

```
streamlit run streamlit_crypto_csv.py
```

Các screenshot trong báo cáo này được sinh tự động bằng `tools/screenshot_streamlit.py` (sử dụng Playwright headless Chromium) để bảo đảm dữ liệu hiển thị nhất quán với kết quả phân tích trong các chương Visualization, OLAP và Data Mining.

## 7 Phân tích, thảo luận và hướng phát triển

### 7.1 Tổng quan kết quả chính

Trong giai đoạn phân tích từ 27/04/2024 đến 26/04/2026, dự án CryptoDW-ETL đã đạt được các kết quả quan trọng:

- **Pipeline ETL hoàn chỉnh:** Thu thập, làm sạch và nạp  $\sim 7300$  dòng dữ liệu vào Star Schema chuẩn – toàn bộ tự động hoá qua `run_pipeline.bat`.
- **Hiệu suất và Lợi nhuận:** Thị trường Crypto thể hiện sự phân hoá cực mạnh. Các đồng nền tảng (BTC, BNB, TRX) có lợi suất ổn định, trong khi nhóm Speculative (ADA, DOGE, DOT, MATIC) ghi nhận drawdown  $-76\%$  đến  $-89\%$ .
- **Anomaly Detection:** Phát hiện 874 phiên bất thường ( $\sim 12\%$  tổng số phiên), trong đó các phiên cực đoan đều có nguyên nhân kinh tế / chính trị rõ ràng (Trump win, ETF approval, Fed policy) – chứng minh hệ thống không phát hiện noise mà phát hiện sự kiện thực.
- **K-Means Clustering:** Phân loại 10 coin thành 3 nhóm Leaders / Mid-cap / Speculative, validated bằng Silhouette score – kết quả nhất quán với phân loại risk-level định tính ban đầu.
- **Hai dashboard song song:** Power BI cho lãnh đạo, Streamlit cho phân tích viên kỹ thuật.

### 7.2 Ý nghĩa và Ứng dụng

Dự án đã biến dữ liệu thô từ sàn Binance thành một hệ thống hỗ trợ quyết định có cấu trúc [12]:

- **Đối với nhà đầu tư:** Dashboard cung cấp cái nhìn tổng quan về rủi ro của từng danh mục coin, hỗ trợ phân bổ vốn tối ưu theo khẩu vị (Modern Portfolio Theory [3]).

- **Đối với nhà quản trị hệ thống:** Quy trình ETL tự động hoá hoàn toàn giúp giảm thiểu sai sót con người và đảm bảo tính kịp thời của thông tin (Data Quality Dimensions [9]).
- **Đối với nghiên cứu:** Kho dữ liệu mở (CSV mode) cho phép tái lập kết quả mà không cần PostgreSQL – minh bạch và phục vụ học thuật.

## 7.3 Hạn chế nghiên cứu

Mặc dù đạt được mục tiêu MVP, nhóm thẳng thắn nhìn nhận các hạn chế nghiêm trọng cần ghi nhận:

### 7.3.0.1 1. Hạn chế về dữ liệu

- **Dữ liệu On-chain:** Hệ thống chỉ sử dụng dữ liệu từ sàn tập trung (CEX). Việc thiếu hụt dữ liệu On-chain (dòng tiền vào/ra ví sàn, hoạt động whales, gas fee) làm giới hạn khả năng dự báo dài hạn.
- **Phân tích tâm lý (Sentiment):** Dự án chưa tích hợp dữ liệu từ mạng xã hội (X/Twitter, Reddit), vốn là yếu tố quan trọng tác động đến giá Crypto – đặc biệt với meme coin như DOGE.
- **MATIC bị delist:** Việc Polygon rebrand sang POL khiến chuỗi dữ liệu MATIC kết thúc 09/2024, không trùng của sổ phân tích chính. Kết quả K-Means cho MATIC vì vậy mang tính tham khảo.

### 7.3.0.2 2. Hạn chế về mô hình

- **Linear Regression** –  $R^2 = 0.96$  là dấu hiệu **data leakage tiềm năng**. Mô hình chủ yếu dự báo  $Close_{T+1} \approx Close_T$  (giá hôm nay là chỉ báo dominant cho ngày mai).  $R^2$  cao trên test set không đồng nghĩa giá trị dự báo thực tế cao – một mô hình “persistence baseline” (luôn dự báo  $Close_{T+1} = Close_T$ ) cũng có  $R^2$  tương đương. Để đánh giá đúng cần đo *directional accuracy* (% đoán đúng chiều) và so với baseline naïve.
- **K-Means trên  $n = 10$  điểm là thống kê yếu.** Với chỉ 10 đối tượng, độ tin cậy của clustering rất hạn chế – đặc biệt khi dữ liệu thay đổi 1 coin có thể làm thay đổi cluster boundary. Silhouette 0.28 ở  $k = 3$  chỉ ở mức “moderate” theo thang Kaufman & Rousseeuw, không “strong”.
- **Z-Score Anomaly giả định stationary.** Chuỗi giá crypto rõ ràng non-stationary – mean và std thay đổi theo thời gian. Z-Score rolling 30 ngày là rough heuristic, không có nền tảng lý thuyết chặt chẽ. Phương pháp tốt hơn: GARCH [8] hoặc Isolation Forest.

### 7.3.0.3 3. Hạn chế về phạm vi

- **Quy mô 10 coin  $\times$  730 ngày** là phạm vi MVP, chưa đủ để rút ra kết luận về toàn thị trường ( $> 10,000$  coin). Việc mở rộng cần xem xét kiến trúc phân tán (Spark/Dask).
- **Không có kiểm thử out-of-sample dài hạn.** Mọi backtest đều thực hiện trên cùng cửa sổ dữ liệu 2 năm – chưa đảm bảo mô hình bền với regime change (ví dụ: chuyển từ bull market sang bear market kéo dài).

## 7.4 Hướng phát triển và đề xuất cải tiến

- **Nâng cấp mô hình ML:**
  - Triển khai *ARIMA* / *GARCH* cho time-series chuyên ngành [8].
  - Thử *LSTM*, *Temporal Fusion Transformer* cho dài hạn (cần dữ liệu lớn hơn).
  - Đo *directional accuracy* thay vì chỉ  $R^2$ .
- **Mở rộng nguồn dữ liệu:**
  - Tích hợp dữ liệu On-chain qua Glassnode / Dune Analytics.
  - Thu thập sentiment qua Twitter API hoặc CryptoCompare News.
  - Thêm dữ liệu vĩ mô (lãi suất Fed, DXY, gold price) làm exogenous features.
- **Hệ thống cảnh báo tự động:**
  - Tích hợp Telegram/Discord webhook khi  $|z| > 2$  kèm Volume Spike.
  - Lên lịch refresh pipeline hàng giờ (cron job) thay vì chạy thủ công.
- **Kiến trúc mở rộng:**
  - Chuyển từ PostgreSQL local sang DuckDB / ClickHouse cho hiệu suất analytical query [15].
  - Triển khai dbt (data build tool) cho transformation tier để dễ test và versioning.
  - Đóng gói dashboard thành Docker để deploy lên cloud.

## Phụ lục

### Phụ lục A: Cấu trúc thư mục dự án

Dưới đây là cấu trúc tổ chức mã nguồn của hệ thống CryptoDW-ETL:

- `ai/`: Chứa các Jupyter Notebook phân tích (Regression, Clustering, Anomaly).
- `scripts/`: Các script Python thu thập dữ liệu từ Binance API.
- `pdi/`: Các tệp Job (.kjb) và Transformation (.ktr) của Pentaho.
- `sql/`: Chứa các kịch bản DDL và DML cho PostgreSQL (Raw, Staging, Gold layers).
- `streamlit_crypto.py`: Mã nguồn ứng dụng Dashboard tương tác.
- `run_pipeline.bat`: Tệp điều khiển chạy toàn bộ luồng ETL.



## Phụ lục B: Đặc tả SQL DDL (Gold Layer)

Đoạn mã SQL định nghĩa bảng sự kiện chính trong Kho dữ liệu:

```
CREATE TABLE gold.fact_market_daily (  
    date_id INT REFERENCES gold.dim_date(date_id),  
    coin_id INT REFERENCES gold.dim_coin(coin_id),  
    open NUMERIC(18,8),  
    high NUMERIC(18,8),  
    low NUMERIC(18,8),  
    close NUMERIC(18,8),  
    volume_usd NUMERIC(20,2),  
    return_pct NUMERIC(10,4),  
    z_score_close NUMERIC(10,4),  
    is_anomaly BOOLEAN,  
    regime_label VARCHAR(16),  
    market_dominance_pct NUMERIC(6,3),  
    PRIMARY KEY (date_id, coin_id)  
);
```

## Phụ lục C: Báo cáo tái sử dụng mã nguồn

Dự án CryptoDW-ETL được phát triển trên nền tảng dự án phân tích cổ phiếu hàng không (project tiền nhiệm cùng nhóm), đạt tỉ lệ tái sử dụng mã nguồn ước tính **~72%**, vượt yêu cầu tối thiểu (70%) của môn học. Bảng 7.1 liệt kê chi tiết các module được tái sử dụng và mức độ điều chỉnh.

**Bảng 7.1:** Báo cáo tái sử dụng mã nguồn – so sánh project tiền nhiệm và CryptoDW-ETL

| Module / Tập gốc                           | Tập mới                  | % reuse | Thay đổi chính                   |
|--------------------------------------------|--------------------------|---------|----------------------------------|
| preprocess_stocks.py (parsers)             | scripts/parsers.py       | 100%    | Giữ nguyên hoàn toàn             |
| preprocess_stocks.py L165–176 (công thức)  | Pentaho Calculator + SQL | 100%    | Cùng công thức, đổi engine       |
| datamining_analysis.py – Linear Regression | ai/01_regression.ipynb   | 80%     | Đổi target, thêm lag features    |
| datamining_analysis.py – K-Means           | ai/02_clustering.ipynb   | 70%     | Thêm validation Elbow/Silhouette |
| datamining_analysis.py – Z-Score           | ai/03_anomaly.ipynb      | 80%     | Đổi static → rolling 30d         |
| olap_analysis.py (pivot)                   | sql/04_olap_views.sql    | 50%     | Đổi từ pandas → SQL views        |
| streamlit.py (Stocks)                      | streamlit_crypto.py      | 70%     | Đổi nguồn CSV → PostgreSQL       |
| Stock_Analysis_Dashboard.pbix              | bi/Crypto_Dashboard.pbix | 60%     | Đổi schema, giữ measures DAX     |

**Cách tính tỉ lệ:** Đo bằng số dòng code thực sự được copy hoặc adapt từ project gốc, chia cho tổng số dòng code trong project mới (không tính file dữ liệu, comment, docstring). Trung bình có trọng số theo độ phức tạp của module:

$$\text{Reuse}_{\text{tổng}} = \frac{\sum_i (\text{LoC}_i \times \% \text{reuse}_i)}{\sum_i \text{LoC}_i} \approx 72\%$$

**Các thành phần được phát triển mới (28%):**

- `scripts/1_fetch_binance.py` – Module ingestion cho Binance API.
- `seed/dim_coin.csv`, `seed/dim_category.csv` – Master data riêng cho crypto.



- `etl/pdi/*.kjb` – Pentaho jobs cho pipeline.
- `run_pipeline.bat` / `.sh` – Orchestration scripts.
- `tools/` – Utility scripts (export PBI, generate images).
- Phần lớn nội dung báo cáo LaTeX và 4 dashboard layouts.

**Thư viện ngoài** (third-party): `pandas`, `numpy` [13], `scikit-learn` [14], `plotly`, `streamlit`, `requests`, `psycopg2`, `sqlalchemy`.

## Tài liệu

- [1] Abonyi, J. & Feil, B., 2007, *Cluster Analysis for Data Mining and System Identification*, Birkhäuser.
- [2] Bishop, C., 2006, *Pattern Recognition and Machine Learning*, Springer.
- [3] Bodie, Z., Kane, A. & Marcus, A., 2014, *Investments*, McGraw-Hill.
- [4] CFA Institute, 2023, *Equity Investments – CFA Program Curriculum*, CFA Institute.
- [5] Chaudhuri, S. & Dayal, U., 1997, *An Overview of Data Warehousing and OLAP Technology*, ACM SIGMOD Record.
- [6] Han, J., Kamber, M. & Pei, J., 2011, *Data Mining: Concepts and Techniques*, Morgan Kaufmann.
- [7] Hull, J., 2017, *Options, Futures, and Other Derivatives*, Pearson.
- [8] Hyndman, R. & Athanasopoulos, G., 2021, *Forecasting: Principles and Practice*, OTexts.
- [9] Inmon, W. H., 2005, *Building the Data Warehouse*, Wiley.
- [10] Binance API Documentation, 2024–2025, *Market Data Endpoints – Klines/Candlestick Data*.  
Truy cập tại: <https://binance-docs.github.io/apidocs/spot/en/>
- [11] James, G., Witten, D., Hastie, T. & Tibshirani, R., 2021, *An Introduction to Statistical Learning*, Springer.
- [12] Kimball, R. & Ross, M., 2013, *The Data Warehouse Toolkit*, Wiley.
- [13] McKinney, W., 2017, *Python for Data Analysis*, O'Reilly.
- [14] Scikit-learn Developers, 2023, *Scikit-learn User Guide*, [scikit-learn.org](https://scikit-learn.org).
- [15] Silberschatz, A., Korth, H. & Sudarshan, S., 2019, *Database System Concepts*, McGraw-Hill.
- [16] TradingView, 2024, *Technical Indicators Documentation*. Truy cập tại: <https://www.tradingview.com/support/>
- [17] VanderPlas, J., 2016, *Python Data Science Handbook*, O'Reilly.